Inteligencia Artificial

Aprendizaje automático

Departamento de Ciencias de la Computación
e Inteligencia Artificial

Universidad de Sevilla

Aprendizaje

- Definiciones de *aprendizaje*:
  - Cualquier cambio en un sistema que le permita realizar la misma tarea de manera *más eficiente* la próxima vez (*H. Simon*)
  - Modificar la representación del mundo que se está percibiendo (*R. Michalski*)
  - Realizar cambios útiles en nuestras mentes (*M. Minsky*)

Aprendizaje

- Aprendizaje automático: construir programas que mejoran automáticamente con la experiencia
- Ejemplos de tareas:
  - Construcción de bases de conocimiento a partir de la experiencia
  - Clasificación y diagnóstico
  - Resolución de problemas, planificación y acción.

Tipos de aprendizaje y paradigmas

- Tipos de aprendizaje
  - Supervisado
  - No supervisado
  - Con refuerzo
- Paradigmas
  - Aprendizaje por memorización
  - Clasificación (*Clustering*)
  - Aprendizaje inductivo
  - Aprendizaje por analogía
  - Descubrimiento
  - Algoritmos genéticos, redes neuronales

Ejemplo de aprendizaje

- Conjunto de entrenamiento
  - Ejemplos: días en los que es recomendable (o no) jugar al tenis
  - Representación como una lista de pares atributo–valor

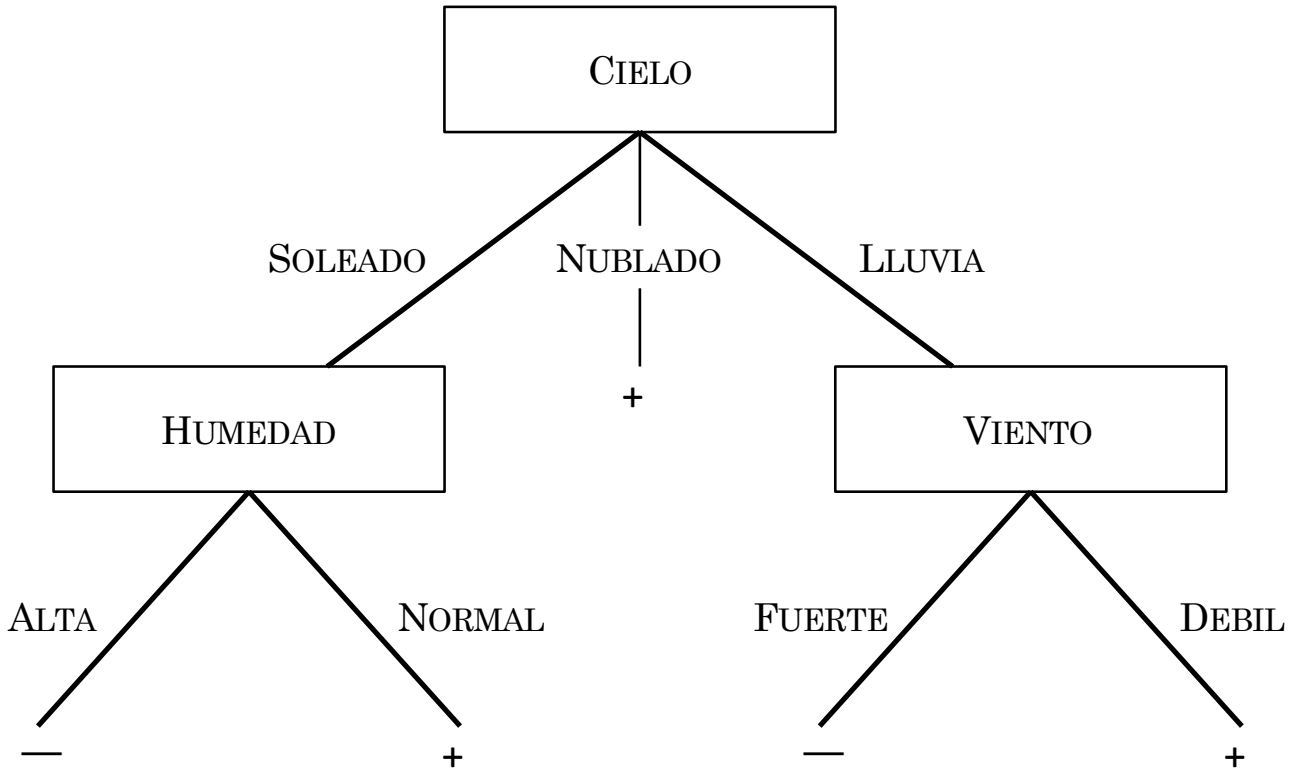
Ej.	Cielo	Temperatura	Humedad	Viento	JugarTenis
D_1	Soleado	Alta	Alta	Débil	-
D_2	Soleado	Alta	Alta	Fuerte	-
D_3	Nublado	Alta	Alta	Débil	+
D_4	Lluvia	Suave	Alta	Débil	+
...					

- Objetivo: Dado el *conjunto de entrenamiento*, *aprender* el concepto «Días en los que se juega al tenis»
  - Se trata de *aprendizaje supervisado*
- Problema: ¿Cómo expresar lo aprendido?
  - En este tema, veremos algoritmos para aprender *árboles de decisión.*

Aprendizaje de árboles de decisión

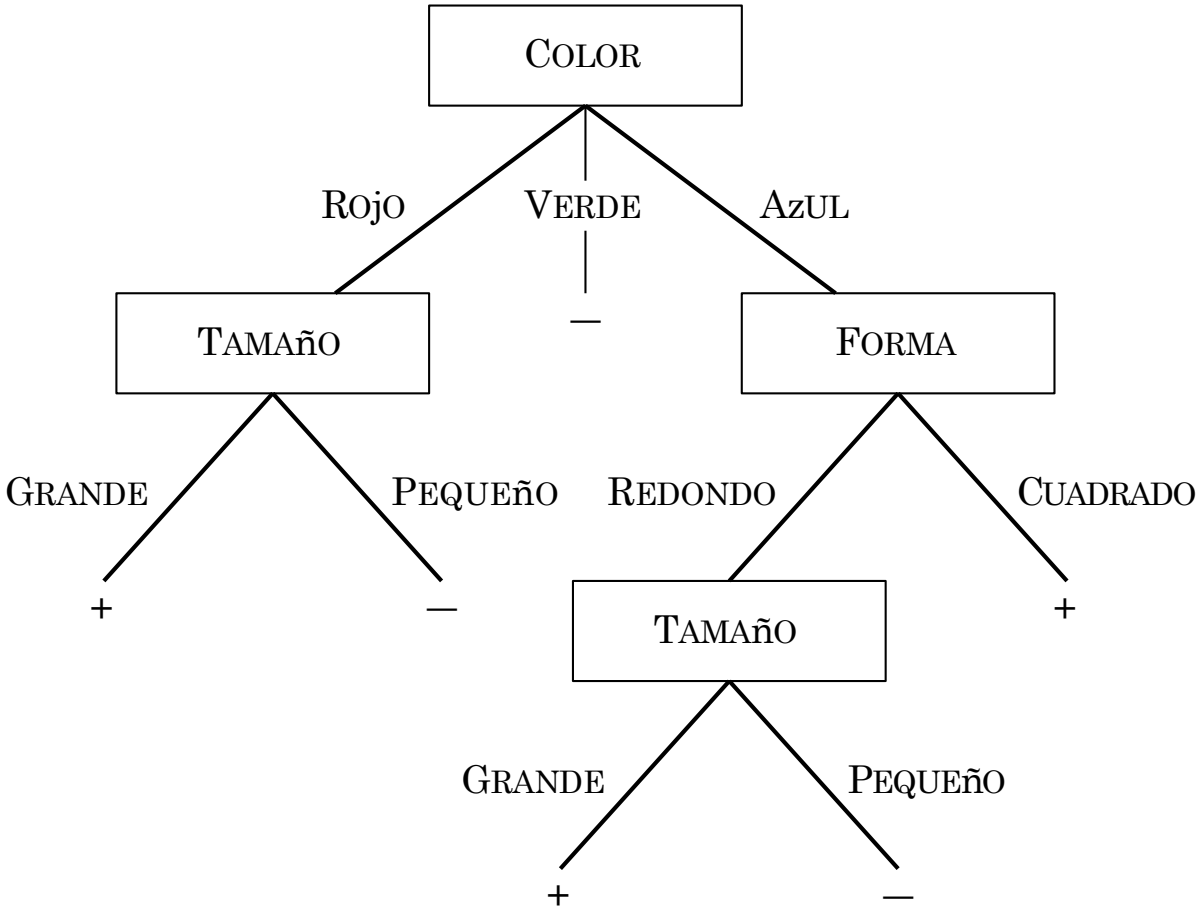
Árboles de decisión

- Ejemplos de árboles de decisión



Árboles de decisión

- Ejemplos de árboles de decisión



Árboles de decisión

- Árboles de decisión
  - Nodos interiores: atributos
  - Arcos: posibles valores del nodo origen
  - Hojas: valor de clasificación (usualmente + ó −, aunque podría ser cualquier conjunto de valores, no necesariamente binario)
  - Representación de una función objetivo
- Disyunción de reglas proposicionales:

$$
\begin{aligned}
&(\text{Cielo=Soleado} \wedge \text{Humedad=Alta} \rightarrow \text{JugarTenis=} -) \\
&\vee (\text{Cielo=Soleado} \wedge \text{Humedad=Normal} \rightarrow \text{JugarTenis=} +) \\
&\vee (\text{Cielo=Nublado} \rightarrow \text{JugarTenis=} +) \\
&\vee (\text{Cielo=Lluvioso} \wedge \text{Viento=Fuerte} \rightarrow \text{JugarTenis=} -) \\
&\vee (\text{Cielo=Lluvioso} \wedge \text{Viento=Debil} \rightarrow \text{JugarTenis=} +)
\end{aligned}
$$

Aprendizaje de árboles de decisión

- Objetivo: aprender un árbol de decisión consistente con los ejemplos, para posteriormente clasificar ejemplos nuevos
- Ejemplo de conjunto de entrenamiento:

Ej.	Cielo	Temperatura	Humedad	Viento	JugarTenis
D_1	Soleado	Alta	Alta	Débil	-
D_2	Soleado	Alta	Alta	Fuerte	-
D_3	Nublado	Alta	Alta	Débil	+
D_4	Lluvia	Suave	Alta	Débil	+
...					

Algoritmo ID3

ID3(Ejemplos, Atributo-objetivo, Atributos)

1. Si todos los Ejemplos son positivos, devolver un nodo etiquetado con +
2. Si todos los Ejemplos son negativos, devolver un nodo etiquetado con -
3. Si Atributos está vacío, devolver un nodo etiquetado con el valor más frecuente de Atributo-objetivo en Ejemplos.
4. En otro caso:
1. Sea A el atributo de Atributos que MEJOR clasifica Ejemplos
2. Crear Árbol, con un nodo etiquetado con A.
3. Para cada posible valor v de A, hacer:
   * Añadir un arco a Árbol, etiquetado con v.
   * Sea Ejemplos(v) el subconjunto de Ejemplos con valor del atributo A igual a v.
   * Si Ejemplos(v) es vacío:
     - Entonces colocar debajo del arco anterior un nodo etiquetado con el valor más frecuente de Atributo-objetivo en Ejemplos.
     - Si no, colocar debajo del arco anterior el subárbol ID3(Ejemplos(v), Atributo-objetivo, Atributos-{A}).

4.4 Devolver Árbol

¿Cómo saber qué atributo clasifica mejor?

- Entropía de un conjunto de ejemplos D (resp. de una clasificación):

$$Ent(D) = -\frac{|P|}{|D|} \cdot log_2 \frac{|P|}{|D|} - \frac{|N|}{|D|} \cdot log_2 \frac{|N|}{|D|}$$

donde P y N son, respectivamente, los subconjuntos de ejemplos positivos y negativos de D

  - Notación: $Ent([p^+, n^-])$, donde $p = |P|$ y $n = |N|$
- Intuición:
  - Mide la ausencia de «homogeneidad» de la clasificación
  - Teoría de la Información: cantidad media de información (en bits) necesaria para codificar la clasificación de un ejemplo
- Ejemplos:
  - $Ent([9^+, 5^-]) = -\frac{9}{14} \cdot log_2 \frac{9}{14} - \frac{5}{14} \cdot log_2 \frac{5}{14} = 0.94$
  - $Ent([k^+, k^-]) = 1$ (ausencia total de homogeneidad)
  - $Ent([p^+, 0^-]) = Ent([0^+, n^-]) = 0$ (homogeneidad total)

Ganancia de información

- Preferimos nodos con menos entropía (árboles pequeños)
- Entropía *esperada* después de usar un atributo A en el árbol:

$$\sum_{v \in Valores(A)} \frac{|D_v|}{|D|} \cdot Ent(D_v)$$

donde D_v es el subconjunto de ejemplos de D con valor del atributo A igual a v

- Ganancia de información *esperada* después de usar un atributo A:

$$Ganancia(D, A) = Ent(D) - \sum_{v \in Valores(A)} \frac{|D_v|}{|D|} \cdot Ent(D_v)$$

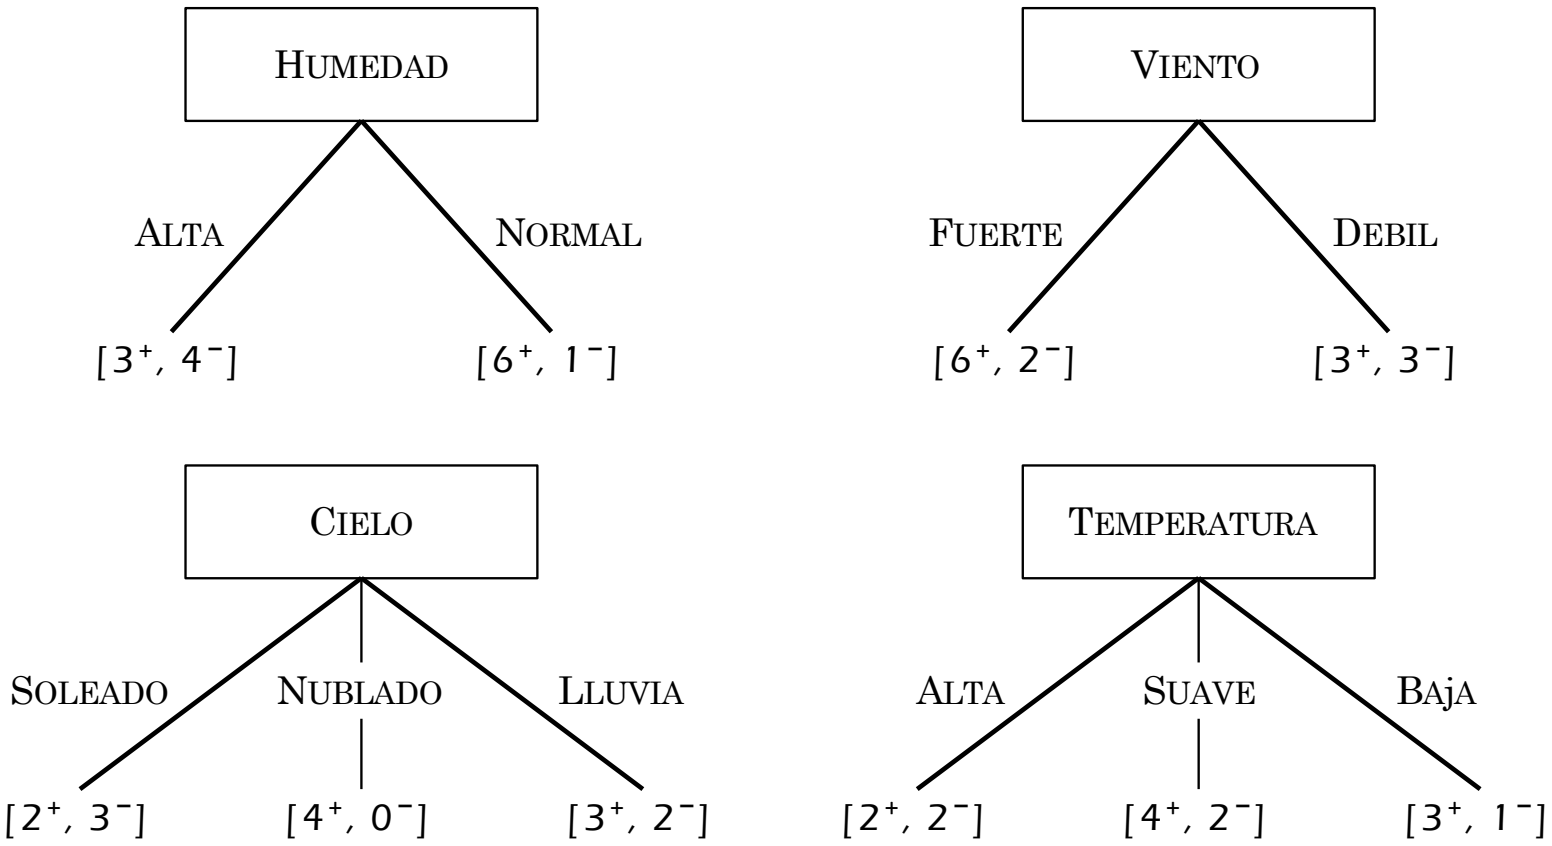
- En el algoritmo ID3, en cada nodo usamos el atributo con mayor ganancia de información (considerando los ejemplos correspondientes al nodo)

Algoritmo ID3 (ejemplo 1)

- Conjunto de entrenamiento:

Ej.	Cielo	Temperatura	Humedad	Viento	JugarTenis
D_1	Soleado	Alta	Alta	Débil	-
D_2	Soleado	Alta	Alta	Fuerte	-
D_3	Nublado	Alta	Alta	Débil	+
D_4	Lluvia	Suave	Alta	Débil	+
D_5	Lluvia	Baja	Normal	Débil	+
D_6	Lluvia	Baja	Normal	Fuerte	-
D_7	Nublado	Baja	Normal	Fuerte	+
D_8	Soleado	Suave	Alta	Débil	-
D_9	Soleado	Baja	Normal	Débil	+
D_{10}	Lluvia	Suave	Normal	Débil	+
D_{11}	Soleado	Suave	Normal	Fuerte	+
D_{12}	Nublado	Suave	Alta	Fuerte	+
D_{13}	Nublado	Alta	Normal	Débil	+
D_{14}	Lluvia	Suave	Alta	Fuerte	-

Algoritmo ID3 (ejemplo 1)

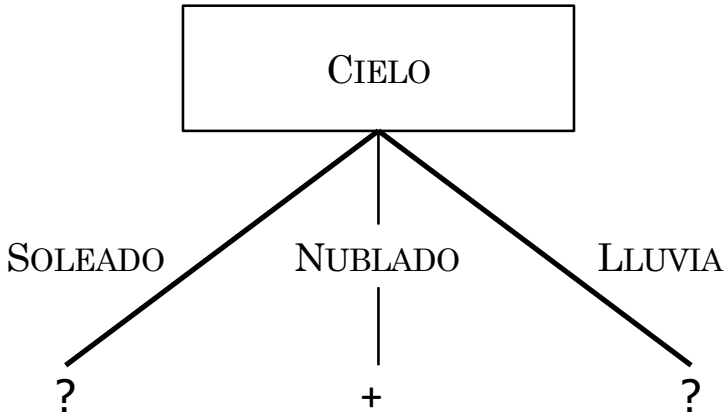


Algoritmo ID3 (ejemplo 1)

- Entropía inicial: $Ent([9^+, 5^-]) = 0.94$
- Selección del atributo para el nodo raíz:
  - $Ganancia(D, \text{HUMEDAD}) =$
    $0.94 - \frac{7}{14} \cdot Ent([3^+, 4^-]) - \frac{7}{14} \cdot Ent([6^+, 1^-]) = 0.151$
  - $Ganancia(D, \text{VIENTO}) =$
    $0.94 - \frac{8}{14} \cdot Ent([6^+, 2^-]) - \frac{6}{14} \cdot Ent([3^+, 3^-]) = 0.048$
  - $Ganancia(D, \text{CIELO}) =$
    $0.94 - \frac{5}{14} \cdot Ent([2^+, 3^-]) - \frac{4}{14} \cdot Ent([4^+, 0^-])$
    $- \frac{5}{14} \cdot Ent([3^+, 2^-]) = 0.246$ (mejor atributo)
  - $Ganancia(D, \text{TEMPERATURA}) =$
    $0.94 - \frac{4}{14} \cdot Ent([2^+, 2^-]) - \frac{6}{14} \cdot Ent([4^+, 2^-])$
    $- \frac{4}{14} \cdot Ent([3^+, 1^-]) = 0.02$
- El atributo seleccionado es CIELO

Algoritmo ID3 (ejemplo 1)

- Árbol parcialmente construido:



Algoritmo ID3 (ejemplo 1)

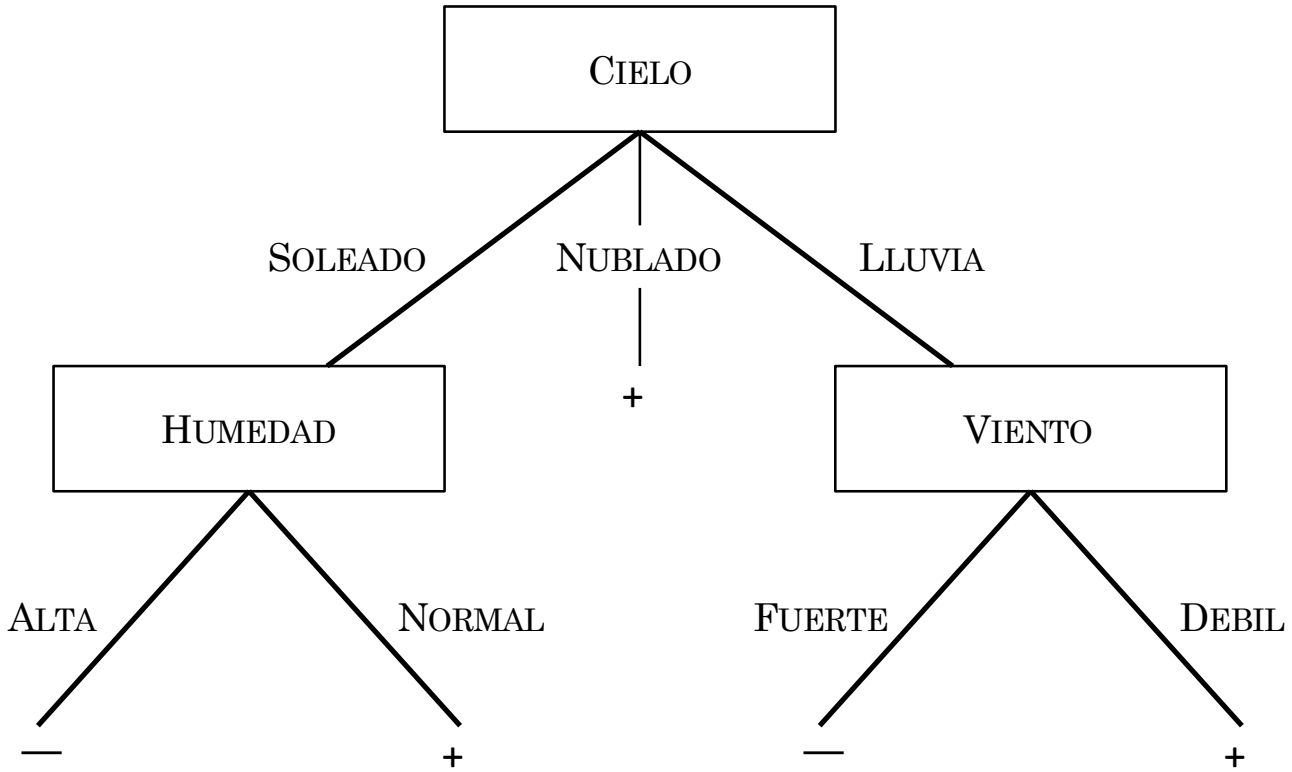
- Selección del atributo para el nodo CIELO=SOLEADO
- $D_{\text{SOLEADO}} = \{D_1, D_2, D_8, D_9, D_{11}\}$ con entropía $Ent([2^+, 3^-]) = 0.971$
  - $Ganancia(D_{\text{SOLEADO}}, \text{HUMEDAD}) = 0.971 - \frac{3}{5} \cdot 0 - \frac{2}{5} \cdot 0 = 0.971$ (mejor atributo)
  - $Ganancia(D_{\text{SOLEADO}}, \text{TEMPERATURA}) = 0.971 - \frac{2}{5} \cdot 0 - \frac{2}{5} \cdot 1 - \frac{1}{5} \cdot 0 = 0.570$
  - $Ganancia(D_{\text{SOLEADO}}, \text{VIENTO}) = 0.971 - \frac{2}{5} \cdot 1 - \frac{3}{5} \cdot 0.918 = 0.019$
- El atributo seleccionado es HUMEDAD

Algoritmo ID3 (ejemplo 1)

- Selección del atributo para el nodo CIELO=LLUVIA:
- $D_{\text{LLUVIA}} = \{D_4, D_5, D_6, D_{10}, D_{14}\}$ con entropía $Ent([3^+, 2^-]) = 0.971$
  - $Ganancia(D_{\text{LLUVIA}}, \text{HUMEDAD}) = 0.971 - \frac{2}{5} \cdot 1 - \frac{3}{5} \cdot 0.918 = 0.820$
  - $Ganancia(D_{\text{LLUVIA}}, \text{TEMPERATURA}) = 0.971 - \frac{3}{5} \cdot 0.918 - \frac{2}{5} \cdot 1 = 0.820$
  - $Ganancia(D_{\text{LLUVIA}}, \text{VIENTO}) = 0.971 - \frac{3}{5} \cdot 0 - \frac{2}{5} \cdot 0 = 0.971$ (mejor atributo)
- El atributo seleccionado es VIENTO

Algoritmo ID3 (ejemplo 1)

- Árbol finalmente aprendido:



Algoritmo ID3 (ejemplo 2)

- Conjunto de entrenamiento:

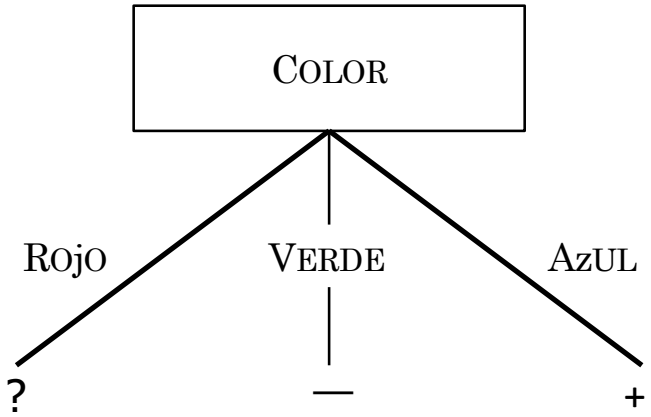
Ej.	Color	Forma	Tamaño	Clase
O_1	Rojo	Cuadrado	Grande	+
O_2	Azul	Cuadrado	Grande	+
O_3	Rojo	Redondo	Pequeño	-
O_4	Verde	Cuadrado	Pequeño	-
O_5	Rojo	Redondo	Grande	+
O_6	Verde	Cuadrado	Grande	-

Algoritmo ID3 (ejemplo 2)

- Entropía inicial en el ejemplo de los objetos, $Ent([3^+, 3^-]) = 1$
- Selección del atributo para el nodo raíz:
  - $Ganancia(D, \text{COLOR}) = 1 - \frac{3}{6} \cdot Ent([2^+, 1^-]) - \frac{1}{6} \cdot Ent([1^+, 0^-]) - \frac{2}{6} \cdot Ent([0^+, 2^-]) = 0.543$
  - $Ganancia(D, \text{FORMA}) = 1 - \frac{4}{6} \cdot Ent([2^+, 2^-]) - \frac{2}{6} \cdot Ent([1^+, 1^-]) = 0$
  - $Ganancia(D, \text{TAMAÑO}) = 1 - \frac{4}{6} \cdot Ent([3^+, 1^-]) - \frac{2}{6} \cdot Ent([0^+, 2^-]) = 0.459$
- El atributo seleccionado es COLOR

Algoritmo ID3 (ejemplo 2)

- Árbol parcialmente construido:



Algoritmo ID3 (ejemplo 2)

- Selección del atributo para el nodo COLOR=ROJO:
- $D_{\text{ROJO}} = \{O_1, O_3, O_5\}$ con entropía $Ent([2^+, 1^-]) = 0.914$
  - $Ganancia(D_{\text{ROJO}}, \text{FORMA}) = 0.914 - \frac{1}{3} \cdot Ent([1^+, 0^-]) - \frac{2}{3} \cdot Ent([1^+, 1^-]) = 0.247$
  - $Ganancia(D_{\text{ROJO}}, \text{TAMAÑO}) = 0.914 - \frac{2}{3} \cdot Ent([2^+, 0^-]) - \frac{1}{3} \cdot Ent([0^+, 1^-]) = 0.914$
- El atributo seleccionado es TAMAÑO

Algoritmo ID3 (ejemplo 2)

- Árbol finalmente aprendido:

