Conceptos básicos · Localización por WiFi

Guía para explicar la presentación en clase · cada concepto aplicado a nuestro ejercicio

1. Aprendizaje supervisado

Qué es: El modelo aprende a partir de ejemplos que ya tienen la respuesta. Luego predice la respuesta en ejemplos nuevos.

En nuestro proyecto: Le damos 2000 mediciones de señal WiFi con la habitación donde se tomaron. Aprende la relación y después, con una medición nueva, dice la habitación.

> Para decirlo en clase: «Le enseñamos al modelo mediciones de las que ya sabemos la habitación, y aprende a adivinarla él solo.»

2. Atributos y resultado (clase)

Qué es: Los atributos son las columnas que usa el modelo para decidir. El resultado o clase es la columna que tiene que predecir.

En nuestro proyecto: Atributos: WS1 a WS7, la señal de cada router. Resultado: Room, la última columna del CSV, con valores 1, 2, 3 o 4 (500 filas de cada una).

> Para decirlo en clase: «Las 7 primeras columnas son la señal de cada router; la última es la habitación, que es lo que queremos adivinar.»

3. Discretización

Qué es: Convertir valores con muchas posibilidades en unos pocos grupos.

En nuestro proyecto: La señal original va de -10 a -98 dBm. La dividimos entre 10 y redondeamos: -64 → -6. Así cada router tiene entre 3 y 8 valores, como el ejemplo de los coches. Cuanto más cerca de 0, más fuerte.

> Para decirlo en clase: «Había demasiados valores distintos, así que los agrupamos de 10 en 10.»

4. Codificación

Qué es: sklearn necesita números enteros desde 0, así que se traducen los valores antes de entrenar.

En nuestro proyecto: OrdinalEncoder para los atributos (-7, -6, -5… → 0, 1, 2…) y LabelEncoder para la habitación (1–4 → 0–3). Por eso en las reglas de sklearn sale `class: 0` = habitación 1.

5. Entrenamiento, prueba y estratificación

Qué es: Se separan los datos: unos para aprender (entrenamiento) y otros, que el modelo no ve, para comprobar si acierta (prueba). Estratificar es mantener el mismo porcentaje de cada clase en los dos grupos.

En nuestro proyecto: 66 % entrenamiento = 1340 filas (335 por habitación) y 33 % prueba = 660 filas (165 por habitación). En los dos grupos sigue habiendo un 25 % de cada habitación. Además, como el CSV viene ordenado por habitación, el reparto mezcla las filas al azar.

> Para decirlo en clase: «Con 1340 mediciones aprende y con las otras 660 lo examinamos, manteniendo el 25 % de cada habitación.»

6. Entropía

Qué es: Mide cuánta duda hay en un grupo, en bits. 0 = no hay duda (todo es de la misma clase). Es máxima cuando todas las clases están igual de repartidas.

En nuestro proyecto: Al empezar hay 4 habitaciones al 25 %: entropía máxima, 2,00 bits.

$$H = - \Sigma\ p \cdot \log_2(p)$$

Grupo	Reparto	Entropía
Todos los datos	25 % · 25 % · 25 % · 25 %	2,00 (máxima duda)
WS1 = -1, -2 o -3	100 % habitación 2	0,00 (sin duda)
WS1 = -4	365 hab. 2 · 8 hab. 3	0,15
WS1 = -6	373 hab. 1 · 15 hab. 3 · 455 hab. 4	1,10
Media tras preguntar por WS1	ponderada por nº de filas	0,71

Para decirlo en clase: «La entropía es la duda. Al principio no sabemos nada (2 bits); al preguntar por el router 1 la duda baja a 0,71».

7. Ganancia de información

Qué es: Cuánta duda quita una pregunta: entropía antes − entropía después. ID3 elige siempre el atributo con más ganancia.

En nuestro proyecto: WS1: 2,00 − 0,71 = 1,29, la mayor. Por eso es la raíz del árbol.

Router	WS1	WS4	WS5	WS6	WS7	WS3	WS2
Ganancia	1,29	1,08	0,88	0,57	0,50	0,33	0,02

Para decirlo en clase: «El router 1 es el que más información da. El router 2 casi no sirve (0,02) porque llega igual a todas las habitaciones».

8. Árbol de decisión (ID3)

Qué es: Una serie de preguntas sobre los atributos. Cada nodo es una pregunta, cada rama una respuesta y cada hoja una predicción. Una hoja es pura cuando solo tiene una clase.

En nuestro proyecto: Nivel 1: ¿WS1? Con -1, -2, -3 → habitación 2 (hojas puras). Nivel 2: en la rama -4 pregunta WS7; en -5, -6 y -7 pregunta WS5. Ejemplo: WS1 = -6 y WS5 = -4 o -5 → siempre habitación 4. El árbol de la presentación es el ID3 con las 2000 filas (para explicar). El del cuaderno es el de sklearn: misma entropía pero preguntas de sí/no (WS1 ≤ -6), 13 niveles y 64 hojas.

Para decirlo en clase: «El árbol va haciendo preguntas, empezando por la que más duda quita, hasta llegar a una habitación.»

9. Porcentaje de acierto y métricas

Qué es: Accuracy: % de aciertos sobre los datos de prueba. Precision: cuando dice «hab. X», cuántas veces acierta. Recall: de las que eran de verdad X, cuántas encuentra. Support: casos de prueba de cada clase.

En nuestro proyecto: Árbol: 97,27 % (642 de 660). Recall: hab. 1 99 %, hab. 2 96 %, hab. 3 97 %, hab. 4 97 %. Support 165 cada una (× 4 = 660). Naive Bayes: 97,12 %.

Para decirlo en clase: «De 660 mediciones que nunca había visto, acierta 642.»

10. Datos externos y formulario

Qué es: Probar el modelo con datos inventados, que no están en el CSV.

En nuestro proyecto: Formulario con 7 desplegables (Muy fuerte … Muy débil). Cada nivel se traduce a su valor, pasa por el OrdinalEncoder y el árbol devuelve la habitación. Truco: empezar en la combinación de la habitación 1 y subir WS1 y WS4 a «Fuerte» → cambia a la habitación 2.

Guion de la presentación

Diapositiva	Idea clave en una frase
1. Portada	Adivinamos la habitación solo con la señal WiFi.
2. La idea	El móvil recibe 7 señales; según su fuerza, sabemos dónde está.
3. Atributos	WS1–WS7, discretizados: -64 → -6. Cerca de 0 = fuerte.
4. Resultado	Room (1–4), 500 de cada. 66 % entrenar / 33 % probar, estratificado.
5. Entropía	De 2,00 bits de duda a 0,71 preguntando solo por WS1.
6. Ganancia	WS1 quita más duda (1,29) → es la raíz.
7. Árbol nivel 1	Una rama por valor de WS1; -1, -2, -3 ya son habitación 2.
8. Árbol nivel 2	WS5 separa las habitaciones 1 y 4; WS7 termina la rama -4.
9. Acierto	97,27 %: 642 de 660 pruebas.
10. Demo	Formulario en directo: de habitación 1 a 2 subiendo WS1 y WS4.

Preguntas que os pueden hacer

- ¿Por qué discretizasteis? Para tener pocos valores por atributo, como en el ejemplo, y poder usar CategoricalNB. El acierto apenas baja (98 % → 97 %).
- ¿Por qué el árbol empieza por WS1? Porque tiene la mayor ganancia de información (1,29).
- ¿Para qué estratificar si las clases ya están equilibradas? Para garantizar que el reparto aleatorio mantenga el 25 % en entrenamiento y en prueba.
- ¿Qué pasa si meto una combinación rara? El modelo siempre devuelve una de las 4 habitaciones, aunque la combinación no tenga sentido real.
- ¿Por qué WS2 no sirve? Vale -5 o -6 en el 99 % de los casos, en todas las habitaciones.