# Práctica de Aprendizaje Supervisado

Resumen rápido · Dataset Wireless Indoor Localization · Árbol de decisión

## 1. El dataset en 30 segundos

Cada fila es una medición: alguien estaba con el móvil en una habitación y se apuntó cuánta señal WiFi recibía de 7 routers. El modelo aprende a hacer lo contrario: le das las 7 señales y te dice en qué habitación estás. Es un problema de clasificación.

| Columna | Qué es | Valores |
|---|---|---|
| WS1 … WS7 | Intensidad de la señal de cada router (en dBm) | Negativos, de -10 a -98 |
| Room | Habitación donde estaba el móvil (columna objetivo) | 1, 2, 3 o 4 |

2000 filas, 500 por habitación (25 % cada una) → dataset equilibrado.

## 2. ¿Por qué los números son negativos?

La señal WiFi se mide en dBm. Cuanto más cerca de 0, más fuerte. Room no es fuerza de señal: es solo la etiqueta de la habitación.

| Valor (dBm) | Señal |
|---|---|
| -30 a -50 | Muy fuerte (cerca del router) |
| -50 a -70 | Buena |
| -70 a -90 | Débil |
| menos de -90 | Casi nula |

## 3. Qué pedía la práctica y cómo está hecho

| Punto | Cómo lo hemos resuelto | Estado |
|---|---|---|
| 1. Elegir CSV y explicarlo | Celda de texto con contenido, atributos (WS1–WS7) y objetivo (Room) | ✔ |
| 2. Instalar paquetes | Celda con `%pip install pandas numpy scikit-learn` | ✔ |
| 3. Entrenar 66/33 estratificado | `train_test_split(test_size=.33, stratify=...)` → 1340 entrenamiento / 660 prueba, 25 % por habitación en ambos | ✔ |
| 4. Pruebas con datos externos | 4 mediciones inventadas → el modelo acierta las 4 (hab. 1, 2, 3, 4) | ✔ |

## 4. Resultado del árbol de decisión

Exactitud (accuracy): 98 % sobre los 660 casos de prueba.

| Habitación | Precision | Recall | Casos |
|---|---|---|---|
| 1 | 0.99 | 0.98 | 165 |
| 2 | 0.98 | 0.96 | 165 |
| 3 | 0.96 | 0.98 | 165 |
| 4 | 0.98 | 0.99 | 165 |

- Precision: cuando dice «habitación X», cuántas veces acierta.
- Recall: de las mediciones que eran de verdad de X, cuántas encuentra.
- En las reglas del árbol sale `class: 0`–3: class 0 = habitación 1, class 1 = hab. 2, etc. (lo cambia el LabelEncoder).

## 5. Diferencias con el ejemplo de los coches

- Leer el CSV: el fichero no tiene cabecera y va separado por punto y coma:

```
wifi = pandas.read_csv('wifi_localization_excel.csv', header=None, sep=';',
        names=['WS1','WS2','WS3','WS4','WS5','WS6','WS7','Room'])
```

- Sin OrdinalEncoder: los atributos ya son números, así que `atributos_codificados = atributos`. Las celdas del encoder están comentadas.
- LabelEncoder sí se usa para Room (1–4 → 0–3).
- Nombres de clase como texto para el informe: `[f"Habitación {c}" for c in codificador_objetivo.classes_]`.
- Datos externos: DataFrame con WS1–WS7 que va directo a `predict`, sin `transform`.
- Sin matriz de confusión.

## 6. Cómo es cada habitación (para las pruebas externas)

| Hab. | Lo que la distingue (mediana de la señal) |
|---|---|
| 1 | Señal media en casi todo, débil en el router 5 |
| 2 | Muy fuerte en los routers 1 (-38) y 4 (-39) |
| 3 | Intermedia en los routers 1–4 (unos -50) |
| 4 | Fuerte en el router 5 (-50), muy débil en el 6 y el 7 |

## 7. Pendiente

- Naive Bayes (parte final del cuaderno): sin hacer. Si hace falta, `CategoricalNB` no vale (no acepta negativos) → usar `GaussianNB`. Si no, comentar esas celdas.
- Antes de exponer: Kernel → Restart & Run All para comprobar que todo se ejecuta sin errores.